

18
08
26

- objeto de dados → há vários pontos:
- ↳ no geral: Tabela/matrix
 - ↳ objeto não é instância que descreve o domínio (linka em um DF). Característica pode ter a não cham
 - ↳ atributos → são as características que descrevem a instância (observação)
 - ↳ cada tipo de dados tem uma nomenclatura própria
 - ↳ atributo pode ter um espaço, é diferente valor de atributo (diferente tipo - unidade de medida)
 - ↳ valor de atributo → diferentes atributos podem ter mesmo tipo/unidade de medida. Alguns entre si podem fazer sentido entre si.
 - ↳ dependendo do tipo de dados que você tem influência no que você pode fazer com ele

There are different types of attributes

— **Nominal**

- ◆ Examples: ID numbers, eye color, zip codes

— **Ordinal**

- ◆ Examples: rankings (e.g., taste of potato chips on a scale from 1-10), grades, height {tall, medium, short}

— **Interval (no true zero (não representa a ausência de valor))**

- ◆ Examples: calendar dates, temperatures in Celsius or Fahrenheit (0° não significa ausência de calor) ($10^\circ\text{C}=50^\circ\text{F}$ and $20^\circ\text{C}=68^\circ\text{F}$).

— **Ratio (true zero exists (representa a ausência de valor))**

- ◆ Examples: temperature in Kelvin, length, counts, elapsed time (e.g., time to run a race), weight (peso=0 = sem peso = ausência de uma determinada quantidade)

↑ zero aqui é ausência

Tem a página em número que
pode ser precedida com número, e
pode ser uma categoria

Distinctness:

$= \neq$

Order:

$< >$

Differences are
meaningful :

$+ -$

Ratios are
meaningful


$* /$

Nominal attribute: distinctness

Ordinal attribute: distinctness & order

Interval attribute: distinctness, order & meaningful
differences

Ratio attribute: all 4 properties/operations



→ pense $0, 1$ (categorias)
 → se input tem
 a não (analisar)
 subconjunto de
 nominal

Record

- Relational records
- Data matrix, e.g., numerical matrix
- Document data: text documents: term-frequency vector
- Transaction data

Graph and network

- World Wide Web
- Social or information networks
- Molecular Structures

Ordered

- Video data: sequence of images
- Temporal data: time-series
- Sequential Data: transaction sequences
- Genetic sequence data

Spatial, image and multimedia:

- Spatial data: maps
- Image data
- Video data

← tipos


→ No caso i bon fazer um
explotação de dados + visualização
↳ plots
↳ bon para ter insight sobre o
dados

→ ponto quanto que o dados estão
em uma estrutura por dados $\leq$ a qual
valor
↳ modo em script

→ Histograma → maneira visual
↳ mostra a distribuição
(alt. simétrica)
↳ em intervalos (bin)
↳ então i.e. quantal de
↳ uma forma de discretizar i
redistribuir o bin em o objetivo
de manter valores contínuos em
uma única faixa, permitindo
o fazer em uma única vez


□ Box Plots

- Invented by J. Tukey
- Another way of displaying the distribution of data
- Following figure shows the basic part of a box plot




grato que a box vai mostrar
a 50% e grato mais vai
diferença

→ Scatter plot → gráfico usado
em variáveis 2D (um
redução de dimensionalidade)
↳ separação de classes



mes de classificação
vão se coarctar aqui





Isolando a relação
entre clare, por natureza britada
é 2 att.

→ Redução de dimensionalidade por
informação (unidade)

→ Matrix plot → heatmap, correlation plot
↳ batata no m
chutings

→ Correlation profile → por via de regra
13 a mais
↳ other m x (Toda
no mesmo modo)
↳ links para cada
interação por modo
direito e valores (7/)



onde o modelo não
consegue explicar
melhor
grande o modelo não
para isso um

Indicateur de données → problèmes → atypique,
nouveau, erreurs, duplications, etc.
↳ causes problèmes
nouveau

Atypique → peut être détecté (pour détecter
des atypiques → erreurs, etc.)
↳ points qui interfèrent (points
hors norme, variables, variées
et variées)

□ Two ways to categorize outlier detection methods:

- Based on whether user-labeled examples of outliers can be obtained:
 - ◆ Supervised, semi-supervised vs. unsupervised (clustering) methods
- Based on assumptions about normal data and outliers:
 - ◆ Statistical (Z-Score), proximity-based (Local Outlier Factor (LOF)), and clustering-based methods (DBSCAN)

⇒ *Usar ϕ para* → *perceber dados e não, ignora ϕ , e pode ignorar*

Handling missing values

- Eliminate data objects or variables
 - ◆ Cuidado para não eliminar demais e tornar a análise inviável – mesmo objetos/variáveis com valores parciais armazenam algum tipo de informação
- Estimate missing values (imputação, próximo slide)
 - ◆ Média (numérico), Moda (categórico), k-NN – porém depende do mecanismo associado a ocorrência – depende do tipo do dado ausente
- Ignore the missing value during analysis
 - ◆ Por exemplo, em um agrupamento, no cálculo da distância, poderia se ignorar atributos com valores ausentes – desde que o número de atributos não seja tão pequeno ou o número de valores ausentes entre os objetos não seja muito alto – distância aproximada

□ Proposta por Rubin, há três mecanismos distintos: MCAR, MAR, MNAR

- A classificação está relacionada ao impacto da ausência de informação (motivo que levou ao não preenchimento da informação) e à escolha da abordagem mais apropriada para análise dos dados

□ Missing completely at random (MCAR)

- Missingness of a value is independent of attributes
- Fill in values based on the attribute → n/a
- Ex. a weighing scale that ran out of batteries. Some of the data will be missing simply because of bad luck

MCAR pode
mean, median,
mode, etc.

↑
Value filter out of range →

❑ Missing at Random (MAR)

- Missingness is related to other variables
- Fill in values based other values
- Ex. if men are more likely to tell you their weight than women, weight is MAR (peso e sexo estão relacionados)

↙ a relação entre variáveis

❑ Missing Not at Random (MNAR)

- Missingness is related to unobserved measurements – somente as variáveis observadas não explicam a ausência de dados
 - ◆ É necessário incorporar o motivo na modelagem para realizar a imputação
- Ex. sickest people are most likely to drop out of the study
 - ◆ Geralmente se avalia outros aspectos (notas, frequências), mas não de uma característica/condição da pessoa que não foi mensurada

↙ a ausência não ocorre no dataset.
Precisa de motivo para imputar o dado

❑ Data set may include data objects that are duplicates, or almost duplicates of one another

- Major issue when merging data from heterogeneous sources

❑ Examples:

- Same person with multiple email addresses
 - ◆ If there are two objects that actually represent a single object, then the values of corresponding attributes may differ, and these inconsistent values must be resolved
 - ◆ Care needs to be taken to avoid accidentally combining data objects that are similar, but not duplicates, such as two distinct people with identical name

→ Data processing

Agregação → dá a ver o objeto em 1

↳ visão mais ampla do dado
↳ redução do obj. a obj
↳ mudança de escala

- Combining two or more objects into a single object - foco em uma visão agregada (mais geral) - OLAP - perdem-se os detalhes
 - Agregar as transações de vendas de uma única loja – visão por loja de uma dada rede
 - Atributos são agregados, por exemplo, somando-se valores (preço) ou gerando-se conjuntos (itens)
- Purpose
 - Data reduction ("consequência")
 - ◆ Reduce the number of attributes or objects
 - Change of scale
 - ◆ Cities aggregated into regions, states, countries, etc.
 - ◆ Days aggregated into weeks, months, or years
 - More "stable" data
 - ◆ Aggregated data tends to have less variability

Sampling → usado para reduzir dados
↳ para análise preliminar

Sampling

- Sampling is the main technique employed for data reduction
 - It is often used for both the preliminary investigation of the data and the final data analysis
- Statisticians often sample because obtaining the entire set of data of interest is too expensive or time consuming
- Sampling is typically used in data mining because processing the entire set of data of interest is too expensive or time consuming

↳ existe critério para amostra
↳ ser representativa

— A sample is **representative** if it has approximately the same properties (of interest) as the original set of data

◆ If the mean (average) of the data objects is the property of interest, then a sample is representative if it has a mean that is close to that of the original data

te

maneira

Característica de população

→ Existe técnica importante
para isso

→ Amostra estatística simples → surge
quando há uma característica

→ Uma população → dados não são
divididos em 1 vez

→ Com repetição → dados podem ser
re-amostrados


Amostra estatística → mantém a mesma
proporção entre classes

□ Stratified sampling

- Used when the population consists of different types of objects, with widely different numbers of objects, simple random sampling can fail to adequately represent those types of objects that are less frequent (imbalanced problem)
- Split the data into several partitions; then draw random samples from each partition
 - ◆ In the simplest version, equal numbers of objects are drawn from each group even though the groups are of different sizes
 - ◆ In another variation, the number of objects drawn from each group is proportional to the size of that group

type
in buckets

Quanto maior a amostra, mais representativa ela é...



8000 points

2000 Points

500 Points

Relação com o tamanho da amostra

→ Feature selection → a the same
 ↳ reduzir dimensão (vão a informação)
 ↳ then → info redundat, info irrelevante, info que se está no meio de alguma coisa, info irrelevante, etc. with redundance
 ↳ low models mais simples, type menos de training
 ↳ técnicas: brute force, filter, wrapper, Embedded
 ↳ não é em wrapper

→ Brute force
 ↳ testa todos os subconjuntos
 ↳ não é viável

→ Filter
 ↳ filtra de acordo com estatística, ranking
 ↳ resolve antes do algoritmo

□ Techniques:

— Filter approaches:

- ◆ Features are selected before data mining algorithm is run



- ◆ Basic Filter Methods (atributos com valores constantes, etc.)
- ◆ Correlation Filter Methods (Pearson, etc.)
- ◆ Statistical & Ranking Filter Methods (ganho informação, informação mútua, etc.)

→ não é wrapper

Filho da correlação + relação de variáveis

- Os coeficientes de correlação são métodos estatísticos para se **medir as relações entre variáveis** e o que elas representam
- O que a correlação procura entender é como uma variável se comporta em um cenário onde outra está variando, visando identificar se existe alguma relação entre a variabilidade de ambas
- Embora não implique em causalidade, o coeficiente de correlação exprime em números essa relação, ou seja, quantifica a relação entre as variáveis

Pearson correlation coefficient [-1, +1]

- It's used to summarize the strength of the **linear relationship** between two data variables
- The assumptions that the Pearson correlation coefficient makes:
 - Both variables should be normally distributed
 - A straight-line relationship between the two variables
 - Data is equally distributed around the regression line


$$\rho = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}$$

https://pt.wikipedia.org/wiki/Coefficiente_de_correla%C3%A7%C3%A3o_de_Pearson

no de E_{-in} , t_{in}

construção é preciso a construção,
tudo mais construção por lá in
with

o tipo de fea depend
de um tipo de ~~construção~~ depend
resposta



→ Wrapper → não queret sair pra fora
↳ estratégia yellow, próximo do
DTF (use for backtracking)
↳ case computing direct
↳ use as algoritmo de ML
e estratégia de busca

forward → Vai por cada feature,
aplica o algoritmo e chama a
utilidade. Seleciona o melhor e
vai novamente aplicando o algo.
com o melhor até o
próximo. Então é um
itinerário de busca


Embedded → parte natural do problema
↳ algoritmo ML já é o
filtro (analisar, 10 exemplos)

Redução de Dim.

→ existe várias maneiras dependentes de
tipo de dados.

→ redução de feature mantendo o dados, aqui
vamos usar modo temporário,

→ loss of dimensionality → a forma a dim. aumenta
dados ficam esparsos e difícil de diferencia
intâncias



Conforme
dimensão
aumenta, a
distância
fica cada
vez menor
(relação entre
max e min)

temos $\rightarrow$ PCA, SVD

PCA $\rightarrow$ pega n variáveis, procura
combinar linhas que não são
correlacionadas entre si

1 Principal Components Analysis (PCA)

- Dadas n variáveis, $V_1, V_2, \dots, V_n$, busca-se encontrar combinações lineares entre elas para produzir variáveis não correlacionadas entre si (cada componente C_i representa uma variável)

$$C_i = \text{coef}_1 * V_1 + \text{coef}_2 * V_2 + \dots + \text{coef}_n * V_n$$

- ◆ As componentes são direções ortogonais que capturam variação nos dados. Cada componente "cobre" um total da variância dos dados (todas=100%)

C_i para
cada
var.

cada componente representa 1/c
da variância de dados

→ Nesse caso, como o número de variáveis é grande, podemos reduzir o número de variáveis que capturam mais variância

→ SVD → projeção dos dados em outro espaço

→ PCA tenta reduzir o erro na projeção e maximizar a variância