

25  
08  
26

PCA → 1- 3 variáveis  
2- Matriz de covariância  
3 → eigenvectors e eigenvalues da matriz

↳ quanto maior a variância carregada por uma variável, mais dispersas as dados

↳ eigenvalue da a quantidade de variância  
↳ o número relativo os eigenvectors pelos eigenvalues

## Principal Components Analysis (PCA)

- Step 3: Compute The Eigenvectors And Eigenvalues Of The Covariance Matrix To Identify The Principal Components

$$v1 = \begin{bmatrix} 0.6778736 \\ 0.7351785 \end{bmatrix}$$

$$v2 = \begin{bmatrix} -0.7351785 \\ 0.6778736 \end{bmatrix}$$

$$\lambda_1 = 1.284028$$

$$\lambda_2 = 0.04908323$$

$$\lambda_1 + \lambda_2 = 1.28 + 0.05 = 1.33$$

1º Componente  
 $1.28/1.33 = 0.96 = 96\%$  variância

2º Componente  
 $0.05/1.33 = 4\%$  variância

\* For a 2-dimensional data set, there are 2 variables, therefore there are 2 eigenvectors with 2 corresponding eigenvalues

<https://builtin.com/data-science/step-step-explanation-principal-component-analysis>

01/27/2020

Introduction to Data Mining, 2nd Edition  
Tan, Steinbach, Karpatne, Kumar

84

PCA is linear (Kernal PCA is  
for non-linear, and there's other  
based on distribution)

Embedding Vectors não que plot para  
o par de features, já que  
embedding já contém info.

Criação de features + criação  
atributos que guardam  
na info que é original  
↳ PCA, named Features, w/ w/ w/  
extração de dados, etc.

Discretização e embedding + gradient  
para dados categóricos

Discretização + num to cat  
↳ gradient para classificação  
e regressão  
↳ den-r = índice de nicho  
categorias (bins)  
↳ long names &  
valores  
↳ não representa o exato  
bin de uma num.  
↳ representação exato bin  
na base de dados

Unsup.  
Vind

- ↳ método linguagem igual →  
(name - sim / sim = iteração)
- ↳ similar à outros
- ↳ repete em intervalos iguais
- ↳ método frequência igual →  
tudo começa sendo v' ch  
oferece o Code bin
- ↳ método + k-mean

Supervi-  
-nd

- ↳ métodos estatísticos
- ↳ bottom up + cada Vals  
valdo ao em intervalos  
reparem ~ Vals / grande  
margem de decisão bin
- ↳ Top down → todo ponto ~  
v' dividindo até  
haver intervalos  
ou sendo homogêneo

Integrar nome caso a gente  
está falando o quanto informa a  
coisas e  
ganha de informação + dados  
em conjunto ou algo homogêneo

a idios i gran parte de repartição  
e se quanto em ~~esta~~ <sup>esta</sup> ~~relevo~~ a  
entropia e quanto de inf. por  
um dado com uma

↳ vai de forma iterativa

One-hot / Encoding → categorias para  
num

Label encoding → categorias para  
num

↳ ordinal

↳ preserva distância entre  
valores

↳ pode ser usado ao modelo  
que há diferença de  
distância entre dados

↳ tem que usar métodos  
baseados em entropia

One-hot encoding → cada categoria  
(dummy) tem um valor  
binário

Dummy Encoding → para N-1 categorias  
de One-hot

On HLT / phony  $\rightarrow$  the problem of  
discrete  $\rightarrow$  supervised

Binary Encoding  $\rightarrow$  label encoding  
requiring de-terministic  
- mapping a binary  $\rightarrow$   
uma coluna por cada bit  
 $\hookrightarrow$  diminuir o problema de  
classificação  
mas o problema do label  
encoding

Transformação de atributos (features)

$\hookrightarrow$   $\log(x)$ ,  $\log(x)$ ,  $e^x$ , etc

$\hookrightarrow$  também pode ser padronização,  
etc. normalização, etc.

qual  
função  
matricial

que transforma

em  $y$  e  $x$  em uma

distribuição normal

(se a distribuição de  
distribuição não for normal)

dependendo pode  
mudar a  
magnitude  
(valor)

$\hookrightarrow$  gradient descent mais rápido  
 $\hookrightarrow$  todos os algoritmos não linear  
e magnitude (KNN, SVM, PCA, etc)  
 $\hookrightarrow$  todos os algoritmos são de uma única

Metoda d'Encade =

- ↳ Z mean  $\rightarrow$  medie  $\approx 0$

- ↳ variatie pana 1

- ↳ pentru a fi dat (artilei tarziu)

- ↳ min/max variat

- ↳ min - Max  $\rightarrow$  Valori  $\approx 0 - 1$

- ↳ similar cu artile

- ↳ se face ranking

- ↳ nu se face a parte

valores positivos  
e não zero

Classificação + ações  $\hat{y} = f(x)$   
onde  $f$  o modelo  
e  $x$  o conjunto de  
atributos

Indução + grande o modelo

dedução + aplicar o modelo

modelo interpretável  $\rightarrow$  modelo onde  
se pode explicar

$\hookrightarrow$  modelo lógico baseado  
em regras de inferência  
modelo e lógica - la

modelo lógico, preciso e difícil  
de interpretar  
 $\hookrightarrow$  NN por exemplo

modelo de lógica simples  $\rightarrow$

modelo que em  
1 instância são interpretáveis,  
mas com uma única  
e precisa uma única  
que interprete o modelo  
 $\hookrightarrow$  Rada é mais por lá.

Não é possível ter todos  
esses critérios ao mesmo tempo,  
então temos que escolher  
o melhor algoritmo (qual),  
CART, ID3, C4.5

Quer't algo.  $\rightarrow$  qual, top down  
 $\hookrightarrow$  pruned:

1. Uma vez definido o crit. Escolha o  
ót. nó que faz a partição  
sem o qual não é possível (na  
entropia)
2. Faz-se iterando em  
cada nó que não é uma folha (pod  
utilizar estes hiperplanos)

Algoritmo pode repetir-se múltiplas  
vezes a cada 2

redução da impureza de  
qual o melhor partição  
 $\hookrightarrow$  índice de Gini, Entropia, mis -  
classificação  
 $\hookrightarrow$  cada uma a partir de partição


→ mai via de diviziune dintr-un c  
 amon mai complex, unde  
 mutual a  $\text{self-fitting}$   
 la indicarea de  $\text{in-junctions}$   
 trece la curia  $\text{varia}$   
 $\text{upward}$

→ Pina  $\text{much}$  + re-partizi<sup>o</sup> binarice (6,5)  
 la  $\text{partizi}$  at<sup>i</sup>  $\text{que}$   
 $\text{que}$   $\text{multa}$   $\text{partizi}$   
 ( $\text{gain ratio}$ ) (6,5)

Divizi<sup>o</sup> tre  $\text{pe}$   $\text{fig}$   $\text{feature}$   $\text{select}$   
 $\text{embedded}$

Nu<sup>o</sup>  $\text{hau}$   $\text{in}$   $\text{construc}$   $\text{itru}$   
 $\text{re}$

## Handling interactions



+ : 1000 instances

o : 1000 instances



Adding Z as a noisy  
 attribute generated  
 from a uniform  
 distribution

Entropy (X) : 0.99

Entropy (Y) : 0.99

Entropy (Z) : 0.98

Attribute Z will be  
 chosen for splitting!



↑ No cano chie por  
que se não fosse refração de luz

No cano 2 a luz não  
se reflete, mas sim  
2 míc. mullido

Amanha via repartição e steps  
vertical e horizontal