

19/26

Ens opant (ens otinto) $\rightarrow$ verifica o ens com san nos deos do trino

Ens de generalizaçã $\rightarrow$ calcula o ens com san em um conjunto aparo de Tert

Ens de clarificação $\rightarrow$ uma matriz de capmão (dua clare)

Matriz de capmão $\rightarrow$ diagad da a amois e a diagad mundâis da o ens

$$\text{amois} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{ens} = \frac{FN + FP}{TP + TN + FP + FN}$$

testam o ens de trino para rali o o noche eto sigle, n eto ide len ou não

overfitting + modelo m. apto a perfitar-se
- entre os dados de treino

underfitting -> modelo : tão simples que
não aprende nem os dados de
treino

há relação
as bias e variância
do modelo

Como chegar ao overfitting -> pouco dados
de treino, alta complexidade do
modelo

Para calcular o erro de generalização

Holdout -> separa treino / test
↳ destaca a subamostra

Repetited Holdout -> por várias rodadas
de Holdout e para
cada uma a média e
desvio padrão
↳ bem para não ficar preso
em 1 conjunto de dados

Bootstrap $\rightarrow$ com repetição
 $\hookrightarrow$ pseudo- n ou o repetido
 Holdout (ou Variação) $\hookrightarrow$
 $\hookrightarrow$ repetição múltipla (pode ser
 estratificada) e o critério
 Vários testes
 $\hookrightarrow$ com plano aleatório
 balanceado
 $\hookrightarrow$ melhorado em performance
 ao usar o -out
 $\hookrightarrow$ número limitado

K-fold cross validation $\rightarrow$ para dados
 estruturados balanceados $K=10$ ou
 múltiplos $K \in \{2, 5\}$
 $\hookrightarrow$ K é o número de divisões
 e de repetições
 $\hookrightarrow$ repetição de dados de forma
 aleatória e o critério teste
 e o critério treino

leave-one-out $\Rightarrow$ cross validation
 também

$\hookrightarrow$ cada vez para 1 vez
 sendo treino e uma vez teste
 $\hookrightarrow$ para amostras pequenas
 $\hookrightarrow$ melhor

Com validação balanceada: 10 vezes para 10 folds. Para
balanço de 5 vezes para 5 folds ou 5 vezes para 2 folds.

É preciso testar várias hiperparâmetros
para ter uma extinção melhor.

Para cada tipo de modelo é
bem definir melhor para o que é um
modelo: desempenho, interpretabilidade,
custo, etc.

Estimar o erro futuro não pode
ser o dado de treino. Sendo
avaliado, para fazer uma avaliação de hiperparâ-
metros, dados de treino / teste, não podem
ser usados. Sendo assim, não deve ter uma
outra partição de validação para
avaliar o melhor hiperparâmetro.

As vezes é necessário, como Holdout,
usar para uma validação para
treino e validação, para garantir
pequena. Costuma ser 80% de treino.
Para isso, você pode:

- Para Holdout para dividir
treino / teste. Para isso, a validação
é para treino e validação.

Para um caso, você faz a triagem
para cada ~~pld~~ ~~de~~ ~~três~~ e ~~valida~~
~~três~~ ~~de~~ ~~casos~~ ~~e~~ ~~antes~~ ~~para~~ ~~e~~
~~valida~~. Depois, você faz o
melhor compare de ~~de~~ ~~de~~ ~~parantes~~
e ~~retorna~~ e ~~valida~~ com os ~~plds~~
da triagem.

- Há também validação cruzada dupl.
1. ~~pld~~ ~~para~~ ~~tet~~ e ~~a~~ ~~parte~~ ~~para~~
triagem. ~~para~~ ~~a~~ ~~parte~~ ~~de~~ ~~triagem~~ e
faz ~~a~~ ~~validação~~ ~~cruzada~~ ~~para~~
validação e triagem. ~~contudo~~ ~~isso~~
é ~~então~~

Dependendo de ~~pre~~-~~processamento~~, e
se ~~for~~ ~~parte~~ ~~de~~ ~~dividir~~ ~~post~~ ~~para~~
~~validar~~ ~~de~~ ~~dados~~.

↳ Por exemplo, se você fizer uma
imputação pela média, a relação
é o ~~o~~ ~~dados~~ ~~de~~ ~~todos~~ ~~os~~ ~~dados~~.

↳ Não tem como saber se ~~for~~ ~~de~~ ~~dividir~~. Isso ~~depende~~ ~~de~~ ~~tratamento~~.
• Dê um ~~para~~ ~~cada~~ ~~pld~~

Precisão $\rightarrow \frac{TP}{TP+FP}$ $\leftarrow$ de quantos
 relacionados com
 positivos não positivos
 Recall $= \frac{TP}{TP+FN}$ $\leftarrow$ de quantos que
 não positivos, quantos
 ele classificou como
 positivos
 para
 positivos e
 negativos

Medida F $\rightarrow$ análise a trade-off
 entre precisão e recall
 Classificar inicialmente positivos
 e a partir daqui que se precisa
 e sobre bastante se precisa

classe positiva é a classe de
 interesse

É geralmente difícil ter precisão
 e recall altos e quanto mais alta
 uma precisão

F1 tem um hiperparâmetro

$F1 = 2 \cdot \frac{\text{Precisão} \cdot \text{recall}}{\text{precisão} + \text{recall}}$

Para matriz de adjacência na
malha 2D, f_{ij} e h_{ij} são
os 2 lados.

↳ isso $\rightarrow$ não deve ter parâmetro
lado lateral individual

↳ $VP = VN$ é a diagonal quadrada
e o resto são
simetria p. lado

↳ cada tipo de medida tem
seu nome, que que o
nome não conta

↳ nome $\rightarrow$ para substituir para
lado de

lado

↳ a partir do lado, todos
calculam o resto

o lado
não é o mesmo
importante

↳ não tem as medidas
são feitas com a medida

↳ mais padronizado $\rightarrow$ mesmo da
medida padrão

↳ geralmente para lado que
vai a input para o lado
maior, e quando for
lado

