


27/09/16

Gradient Boosting $\rightarrow$ minimize loss
 $\hookrightarrow$ model can be seen as direction
 as gradient negative!
 direction of steps!
 $\hookrightarrow$ combine models of low
 bias and high variance
 $\hookrightarrow$ use a model, pass a
 part, use a previous one
 to be better



$\hookrightarrow$ gradient o model can be used
 as a
 $\hookrightarrow$ use a set of rules for finding
 the best model, but
 entering a procedure
 $\hookrightarrow$ not good, rapidly
 $\hookrightarrow$ use a model, can be used
 in a good way

- ↳ a primeira medida F_0 é um chute ao acaso
- ↳ medida usada no training em T_1
- ↳ medida é o gradiente calculado
 - ↳ é usado para calcular F_{t+1}
- ↳ learning rate pode ser fixo ou
 - ↳ pode ser gradiente
- ↳ existem vários tipos de bagging
 - ↳ split da lista e coloca em
 - ↳ cada uma a mesma subamostra de
 - ↳ coloca cada um de cada split
 - ↳ aumenta a variabilidade

Random Forest

- ↳ ensemble Homogeneo
- ↳ manipula o conjunto de treino
 - ↳ a feature

1. bootstrap para cada amostra (ou seja, bagging)
2. Para cada amostra
 - 2.1. para cada nó interno
 - na decisão de qual p atributo usar para split
 - 2.2. split de T_1 no meio

- ↳ uma gran não pedada (barro
3 ou 4 variações)
- ↳ rede de variações
- ↳ p. e. m. 14% parâmetros
 - ↳ ↓ herd. conclusivos
 - ↳ ↑ m. de variações
- ↳ quando Jd1 ou $bg_2(d+1)$
 - ↑ dimensão

- ↳ onde não impedido ~ não
continua igualmente
- ↳ mais rápido (pachos) do que
gradiente 200%

Enables Heterogeneity

- ↳ continua mais
- ↳ aumentar a força de seleção
quando mais difere
- ↳ medidas que podem variar diferentemente
de cada / linha, radial, não linear, etc

Stacking

- ↳ Várias medidas diferentes não têm sentido
- ↳ um único medida é sentido
- ↳ não são mais outras
 - ↳ se quando as outras
não

Método	Como gera diversidade?	Treinamento	Como combina?	Ideia principal
Bagging	Amostras bootstrap ✓	Paralelo	Votação / média	↓ principalmente variância
Random Forest	Bootstrap + subconjuntos de atributos ✓	Paralelo	Votação / média	↓ variância e correlação entre árvores
<u>AdaBoost</u>	Reponderação dos exemplos	Sequencial	Votação ponderada	↓ principalmente bias, focando exemplos difíceis
Gradient Boosting	Ajuste do gradiente negativo da loss	Sequencial	Soma sequencial das correções	↓ principalmente bias, corrigindo erros sucessivamente
Stacking	Diferentes modelos	Em níveis	Meta-modelo	Aprende como combinar as predições

Similaridade / distância

- ↳ em conjunto precisamos saber o quão dois objetos são similares
- ↳ proximidade por se similaridade e dissimilaridade

similaridade

- ↳ quão iguais
- ↳ escala de $[0, 1]$ é intuitiva

dissimilaridade

- ↳ complemento da similaridade
- ↳ quanto mais diferente, mais diferente
- ↳ mínimo 0 e máximo não há
- ↳ distância é um caso especial de dissimilaridade

Attribute Type	Dissimilarity	Similarity
Nominal	$d = \begin{cases} 0 & \text{if } x = y \\ 1 & \text{if } x \neq y \end{cases}$	$s = \begin{cases} 1 & \text{if } x = y \\ 0 & \text{if } x \neq y \end{cases}$
Ordinal	$d = x - y / (n - 1)$ (values mapped to integers 0 to $n-1$, where n is the number of values)	$s = 1 - d$
Interval or Ratio	$d = x - y $	$s = -d, s = \frac{1}{1+d}, s = e^{-d},$ $s = 1 - \frac{d - \min_d}{\max_d - \min_d}$

distance
(manhattan, Euclidean)

distance depends
on type of data

Euclidean distance is used in many scales (Standard)

Minkowski Distance

- Minkowski Distance is a generalization of Euclidean Distance

$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_{k=1}^n |x_k - y_k|^r \right)^{1/r}$$

Where r is a parameter, n is the number of dimensions (attributes) and x_k and y_k are, respectively, the k^{th} attributes (components) or data objects x and y .

Manhattan = City Block

Common Properties of a Distance

- Distances, such as the Euclidean distance, have some well known properties.

1. $d(x, y) \geq 0$ for all x and y and $d(x, y) = 0$ if and only if $x = y$.
2. $d(x, y) = d(y, x)$ for all x and y . (Symmetry)
3. $d(x, z) \leq d(x, y) + d(y, z)$ for all points x, y , and z . (Triangle Inequality)

where $d(x, y)$ is the distance (dissimilarity) between points (data objects), x and y .

- A distance that satisfies these properties is a **metric**

in a metric you can show for any x, y, z , the distance between x and z is less than or equal to the sum of the distance between x and y and the distance between y and z .

Common Properties of a Similarity

- Similarities, also have some well known properties.

1. $s(x, y) = 1$ (or maximum similarity) only if $x = y$. ($0 \leq s \leq 1$)
(does not always hold, e.g., cosine)
2. $s(x, y) = s(y, x)$ for all x and y . (Symmetry)

where $s(x, y)$ is the similarity between points (data objects), x and y .

Similarity Between Binary Vectors

- Common situation is that objects, x and y , have only binary attributes

- Compute similarities using the following quantities

f_{01} = the number of attributes where x was 0 and y was 1

f_{10} = the number of attributes where x was 1 and y was 0

f_{00} = the number of attributes where x was 0 and y was 0

f_{11} = the number of attributes where x was 1 and y was 1

- Simple Matching and Jaccard Coefficients

SMC = number of matches / number of attributes

$$= (f_{11} + f_{00}) / (f_{01} + f_{10} + f_{11} + f_{00})$$

Counts both presences and absences equally
– students who had answered questions similarly on a test only of true/false questions

J = number of 11 matches / number of non-zero attributes

$$= (f_{11}) / (f_{01} + f_{10} + f_{11})$$

Frequently used to handle objects consisting of asymmetric binary attributes – products purchased by customers

valida
a partir
das
frequência
binária

contador

note que
do mesmo
modo

para o Jaccard

em um caso, a parâmetro
quatro atributos da unidade
condicionada

→ pode-se calcular similaridade em dimensionalidade não binária

Cosine Similarity

- A similarity measure for documents needs to ignore 0-0 matches like the Jaccard measure, but also must be able to handle non-binary vectors.

	team	coach	play	bell	score	game	win	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	2
Document 2	0	7	0	2	1	0	0	3	0	0
Document 3	0	1	0	0	1	2	2	0	3	0

CÁLCULO DO ÂNGULO ENTRE DOIS VETORES




Figure 2.16. Geometric illustration of the cosine measure.

Em caso de palavras em documento, se não digamos se há ou não o elemento a quantidade é importante para Jaccard nesse caso

Nesse caso, similaridade de cosseno é Jaccard para vetores não binários

Cosine Similarity

- A similarity measure for documents needs to ignore 0-0 matches like the Jaccard measure, but also must be able to handle non-binary vectors.

$$\cos(x, y) = \frac{\langle x, y \rangle}{\|x\| \|y\|} \quad \langle x, y \rangle = \sum_{k=1}^n x_k y_k \quad \|x\| = \sqrt{\sum_{k=1}^n x_k^2} = \sqrt{\langle x, x \rangle}$$

CÁLCULO DO ÂNGULO ENTRE DOIS VETORES




Figure 2.16. Geometric illustration of the cosine measure.

$\langle x, y \rangle$ = the inner product of the two vectors
 $\|x\|$ = the length of vector x

Quando 1, está o ângulo:

quando 0, não são L

não há a coincidência a
suficiente (por não não)

Quando tipo, dado não pode-
-rão, localizar, não, não pode-
-ar, a dimensão.
Para não event um número

General Approach for Combining Similarities

- Sometimes attributes are of many different types, but an overall similarity is needed.

1: For the k^{th} attribute, compute a similarity, $s_k(\mathbf{x}, \mathbf{y})$, in the range $[0, 1]$.

2: Define an indicator variable, δ_k , for the k^{th} attribute as follows:

$\delta_k = 0$ if the k^{th} attribute is an asymmetric attribute and both objects have a value of 0, or if one of the objects has a missing value for the k^{th} attribute

$\delta_k = 1$ otherwise

3. Compute similarity($\mathbf{x}, \mathbf{y}$) =
$$\frac{\sum_{k=1}^n \delta_k s_k(\mathbf{x}, \mathbf{y})}{\sum_{k=1}^n \delta_k}$$

δ_k diz se vai ou não usar
ou não
pode ser adicionado, pois também

Contextualização

↳ é um problema

↳ poder haver 2 diferentes clusters
em diferentes contextos

↳ cada algo. vem de uma forma diferente
e dados para agrupar

↳ encontrar clusters que são o mais
similares possíveis entre si - entre diferentes
clusters o mais similares possíveis

↳ pode se usar para: entendimento de
dados, anotações,
unificação, etc. outras

→ Partitioned → nœuds les uns appartenant à
groupes
→ Hierarchique → les uns appartenant (dendrogramme)

Other Distinctions Between Sets of Clusters

□ Exclusive versus non-exclusive

- In non-exclusive clusterings, points may belong to multiple clusters.
- Can represent multiple classes or 'border' points

→ peut appartenir à plus d'un groupe

□ Fuzzy versus non-fuzzy

- In fuzzy clustering, a point belongs to every cluster with some weight between 0 and 1
- Weights must sum to 1
- Probabilistic clustering has similar characteristics

→ tous les points appartenant à tous les groupes avec un poids différent

□ Partial versus complete

- In some cases, we only want to cluster some of the data

→ tous les nœuds appartenant à un groupe ou non

□ Heterogeneous versus homogeneous

- Clusters of widely different sizes, shapes, and densities

→ différents groupes

Exister d'autres critères. Les types peuvent avoir d'autres caractéristiques.

Catégories

- Clusters bien séparés
 - ↳ les points de parts bien groupés
 - ↳ isolés
 - ↳ peut être quelques points

- Banco de centro

- K-Nearest
- ↳ O laço ideal não existe, estão aí
 - ↳ mesmo Vanilla
- Softmax
- ↳ Cada grupo tem um centro e
 - ↳ um ponto não próximo dele
 - ↳ Centro = ponto representativo (vão dar de lado)
 - ↳ Lida de cada parte no grupo
 - ↳ medida → ponto nel do seguinte para
 - ↳ cada centro (geralmente integrado)

- Banco de Vigilância

- ↳ Cada parte é mais próximo de
- ↳ pelo menos um ponto do cluster do
- ↳ que de outro cluster
- ↳ bom para pontos difíceis de
- ↳ circular

- Banco de densidade

- ↳ Cluster de região com muita parte
- ↳ aponta para região de baixa parte
- ↳ DBSCAN
- ↳ bom para ruído e outliers

K-Nearest → precisa entender o dado

- ↳ definir uma métrica (distância) (para
- ↳ todos os dados)
- ↳ precisa definir o número K de clusters

1. Infirma central
2. Ampla parte se catur pe distan
3. Recupere a central (ridic la Kuan)
4. Repet de clasa criteri

Na definição de nirmu e wa de
 Ena se quadrado (SSE) - no pte mda
 capere a mda. Exante (Kuan, pare pda,
 K-plied pare wa, etc

dentado
de mda

mau a rodado co a mda chao
 (mai nirma)

conce rápido

Entre nirma implica no sentido.
 Gerente rod-m varia vge co entre
 nirma

- ↳ Rod-m ma tan Ben Kuan + e,
 Diret Kuan
- ↳ Rod-m ma mda Hicquise
 tan be

Kuan + e → pte a pima central de
 pena chobis
 ↳ mda a pima mda pte
 distante de pima

↳ for o nome dividido as partes
cathéd e mais long point

Na verdade, cada parte recebe uma
prod. em bom e uma distância. Então
maneira e distância, mais e prod.

Direct Kneer → Vunão Kneer e Hilargie
↳ Top down na Hilargie
↳ Longe em um wide shot em
Turbo

Volta
chute
em bom
em um hitte,
com
maneira S&E
↳ pegue em chute e prod. n
Vunão Kneer e Hilargie
K = L (de muita circulação)
↳ volta a de novo S&E e colina na
Hilargie

podem ser as catenais de
folha para uma longa catenais inicial.

um dos três são de um ótimo global,
já que é grande parte. Assim que
um para as catenais inicial melhor

Knead has a plaque from teeth
or fracture of clitoris, gradually globular
net

Também é possível à artéria (unha
ante é unha)

Surina é dividida difere

Pode ser mais suave e depois mais
Hiragura para cada e suave antes