

06
12
26

→ Cluster Hierarquias

↳ pode ser visualizada como um dendrograma


↳ representa como os grupos foram formados (hierárquico)

↳ pode ser criado bottom-up ou top-down


↳ pode-se aplicar o cluster de alguma forma

Hierarchical Clustering

- Produces a set of nested clusters organized as a hierarchical tree
- Can be visualized as a dendrogram
 - A tree like diagram that records the sequences of merges or splits



Dendrogram



Nested cluster diagram

02/14/2018

Introduction to Data Mining, 2nd Edition

51

↑ grupos formados logo de início, não são muito similares enquanto que aqueles que demoraram mais não são muito similares a todos os outros

dados e
hubs ()
de fato
em y, pode-se
representar o
grupo

→ alguns problemas são estruturais

→ both up & down the
ports ring & vai pentado
→ top da 1° unidade em de
interior da torre & vai
impedida (Biret Kneam
por bloqueio)

→ Precisa de uma notificação de proximidade

→ provincialidade, não grandeza
e um não um triângulo
nuprio e distigido e cada
modificação

Erwarte gar nichts! Ich liebe

- ↳ pois o pai de uma ditadora
- ↳ Ytina e ditadora de
- ↳ aludize e matize retirando
- o nas repara e edificando
- o guerra e na ditadora em
- cada par

- ↳ polimerizări între grupii
fita care a par faza de
a nivel distal în
- ↳ urmare chetă clustre de
lanțuri diferite

↳ ierarhizarea activitatilor
peste o parte de timp
intra grupa

⇒ Mean / Length of Day
↳ varianta a de lucru distanta
↳ studierea intrun a noie
distanta
↳ metoda metinut a activitatilor
↳ lucru a grupelor clustere
a grupelor clustere

⇒ Group Average
↳ Ainde unel a var
↳ a activitatilor de lucru a
reduc de distanta
↳ metoda a metinut
↳ grupelor clustere

⇒ Metode de Lucru
↳ activitatilor de lucru
↳ metoda SSC
↳ un a var intra grupa a grupelor
reduc de distanta
↳ lucru a grupelor clustere
↳ metoda metinut a activitatilor

des autres parties, tout est grand,
pour le, pour le, pour le, pour le, pour le,
 $O(N)$ en espace, $O(N^2)$ temps

→ $\vec{t}$ in Methode Subst (nur backtracking)

→ ~~time~~ a work here to focus
offline

→ Entschult wie super Sam

→ DBSCAN

→ barocke en climisch

→ polímero rígido, densa no espaço

→ também faz detecção de
outliers, p. ex. não há um
grupo muito completo, e ex. não
estão em uma região densa e
muito

→ mesure effectuée en vase & l'air (vase plein)

→ para cada patho V_n quanto
várias vezes dentro do mesmo
raio - classificação e
categoria

→ car → etc - no name - power
night vigils

→ $\text{Link} \rightarrow$ a vizinhança de um nó,
nas páginas vizinhas
→ não é uma coleção (ignora em)

→ Para cada grupo de vizinhos para cada grupo
capítulo a vizinhança. Se um ponto
que não pode ser distinguido de outros
distinguido de outros

→ É sobre a quantidade de
clustering automático

→ É o número de pontos de
clustering de pontos

→ É dependente de vários hiperparâmetros
como o número de clusters e o
hiperparâmetro

→ É o número de pontos para
para cada ponto capítulo
a distância entre cada outro
ponto, onde se pode par
não é a mesma a distância
de K pontos, então o valor
é a mesma a distância de
um ponto e tem o
valor K mais vizinhos

→ agrupamento: não refinado

→ Medidas de similaridade de clusters

→ ligação → quão similares os clusters
em um grupo

→ separação → quão distantes são os
clust. de um grupo em outro
grupo

→ medida não refinada (intuitiva)
↳ calcula a ligação de cada grupo
- entre si, faz uma média e isso
produzido pelo menor de itens
↳ o menor para separação

→ Em algoritmos baseados em centro,
a ligação para um cluster é a distância
do centro

↳ cada item possui distância
medida de ligação e separação

→ Medida de silbath → ligação e separação

↳ para cada parte p_i $S_i = (b - a) / \max\{a, b\}$
a e b são distâncias p_i p_j p_k p_l p_m p_n p_o p_p p_q p_r p_s p_t p_u p_v p_w p_x p_y p_z
parte do cluster
↳ a distância mínima entre
a parte e a outra de um cluster


→ silhetti do clu e a medi
da silheta das partes do clu
→ U_i de -1 a 1

□ The Silhouette Coefficient

- O coeficiente silhueta, SC, é o máximo $\bar{s}(K)$ para $K = 2, 3, \dots, (n - 1)$
- SC é uma medida da quantidade de estrutura descoberta por um algoritmo de agrupamento
 - ◆ $SC \leq 0.25$ significa que não foi encontrada uma estrutura substancial
 - ◆ $0.26 \leq SC \leq 0.5$ indica que a estrutura encontrada é fraca e pode ser artificial
 - ◆ $0.5 \leq SC \leq 0.7$ significa que uma estrutura razoável foi encontrada
 - ◆ $0.71 \leq SC \leq 1$ indica que foi encontrada uma estrutura forte

→ Pod-se avaliar parte
do silheto para estruturas
pouco preditivas

→ Mapas de calor podem ligar o ponto
e indicar qual a similaridade



→ S. Math grade a azata
o número de K para dedução

→ para K mean poly - a pta SSE
ps K - a média o valor

→ Método superior para
validação

↳ quando não há a
chave cada inteiro
potência (grand, truth)

↳ modo para validar a
a estrutura existente
relativa a valide, onde
outra estrutura pode existir

↳ a o modo a prova
de conteúdo, isso pode ser
modo para clarificar

↳ pode ser a estrutura ps
inibida ou clarificação

↳ a estrutura a clarificação
↳ a chave repetitiva
referente a estrutura e q
a label vai
↳ pode ser mais ch e
estrutura ps chave

6. a. não é possível definir
 a palavra a partir da
 de classificação como T, por
 , real, etc.
 6. b. não é possível de definir ple
 namente, pode-se definir
 a classe de de cluster
 de de e próximo para
 cada classe

→ Orientado a similaridade → quanto
 de pontos que estão em
 em uma cluster estão em
 uma classe
 6. colocação entre pontos de
 cluster - classe
 6. colocação de pontos

Similarity-Oriented Measures of Cluster Validity

- Take the correlation of these two matrices as the measure of cluster validity (**known as Hubert's Γ statistic (correlação de Pearson)**)
- Consider five data points, p1, p2, p3, p4, and p5, two clusters, $C1 = \{p1, p2, p3\}$ and $C2 = \{p4, p5\}$, and two classes, $L1 = \{p1, p2\}$ and $L2 = \{p3, p4, p5\}$. The ideal cluster and class similarity matrices are given in Tables 7.10 and 7.11. The correlation between the entries of these two matrices is 0.359.

Table 7.10. Ideal cluster similarity matrix.

Point	p1	p2	p3	p4	p5
p1	1	1	1	0	0
p2	1	1	1	0	0
p3	1	1	1	0	0
p4	0	0	0	1	1
p5	0	0	0	1	1

Table 7.11. Class similarity matrix.

Point	p1	p2	p3	p4	p5
p1	1	1	0	0	0
p2	1	1	0	0	0
p3	0	0	1	1	1
p4	0	0	1	1	1
p5	0	0	1	1	1

↑
 parte entre
 as duas clusters

↑
 parte entre
 as duas classes

de calcul a calculat de
trans este notat,
guarante, mai putina de
1 sube

□ Similarity-Oriented Measures of Cluster Validity

- We can convert these two matrices into binary vectors

f_{00} = number of pairs of objects having a different class and a different cluster

f_{01} = number of pairs of objects having a different class and the same cluster

f_{10} = number of pairs of objects having the same class and a different cluster

f_{11} = number of pairs of objects having the same class and the same cluster

$$\text{Rand statistic} = \frac{f_{00} + f_{11}}{f_{00} + f_{01} + f_{10} + f_{11}}$$

$$\text{Jaccard coefficient} = \frac{f_{11}}{f_{01} + f_{10} + f_{11}}$$

Calculator pentru pag de fac
binar

→ algoritma de clustere prin
inertie sau a structurii

→ K-medoids

- + un centru dat de un
→ un centru fixat in
mai mult de un centru
→ un centru fixat pe centru