13/10/26

→ Associação é uma tarefa
- ↳ não supervisionada
- ↳ interpretável
- ↳ descoberta de relacionamentos escondidos entre os itens do dataset
- ↳ tudo é baseado em itemset
- ↳ é usada matriz de transação id, itens
- ↳ implicação não denota causalidade, mas co-ocorrência
  - ↳ para ter causalidade precisa-se saber as variáveis de causa e efeito

→ itemset → conjunto de elementos
→ k-itemset → conjunto com k itens

→ suporte absoluto → quantas vezes o mesmo itemset aparece

→ suporte relativo → porcentagem de transações que aparecem aquele itemset (abs / total)

→ itemset frequente → itemset com frequência ≥ a um threshold

$X \rightarrow Y \mid X, Y$ são itemsets
$X \cap Y = \emptyset$ ← item não pode estar em X e Y ao mesmo tempo

→ confiança → quão frequente Y
aparece em transações que
aparece X → $(\sup(X \cup Y) / \sup X)$

→ Força bruta não faz sentido dado
que algumas regras provavelmente
vão não úteis, (não frequentes)

→ Por isso a gente pode primeiro
gerar os itemsets frequentes (mais
custosos) e depois gera as
regras

→ Para reduzir o número de
transações se pode por exemplo
usar apenas as transações de
tamanho ≤

→ Apriori
→ propriedade anti-monotônica
do suporte

$$\forall X, Y : (X \subseteq Y) \Rightarrow s(X) \geq s(Y)$$

se X é menor do que Y
então é muito mais fácil ter
X em um itemset do que X

→ 1º encontro todos os itens únicos
2º podes considerar nenhum frequente dado um suporte mínimo
3º faço o próximo para tamanho 4, e repito até nenhum seja frequente

→ itemsets (regras) maiores que 7 não são fáceis de interpretar

→ o algoritmo deve ser completo: não omite itens frequentes, e não redundante, não gera o mesmo candidato 2x, e [illegible] não gera candidatos desnecessários
↳ para garantir essa última, os itens sempre estão em ordem alfabética.

gera [illegible] itens. regras

a ordem garante que seja possível gerar com não redundância

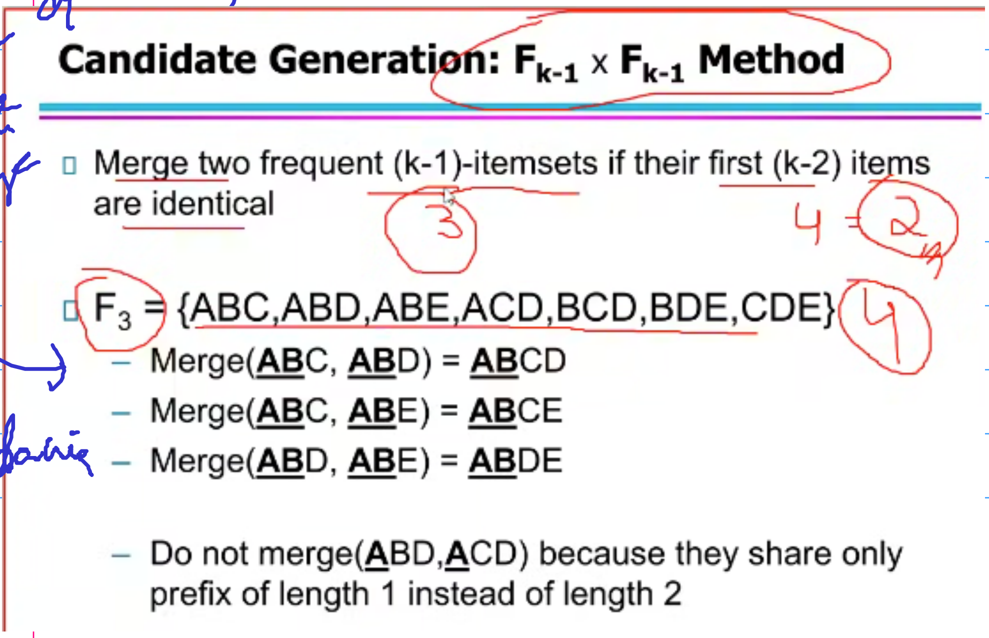

Candidate Generation: $F_{k-1} \times F_{k-1}$ Method

- Merge two frequent (k-1)-itemsets if their first (k-2) items are identical

3   4 = 2

- F_3 = {ABC,ABD,ABE,ACD,BCD,BDE,CDE}   4
  - Merge(**AB**C, **AB**D) = **AB**CD
  - Merge(**AB**C, **AB**E) = **AB**CE
  - Merge(**AB**D, **AB**E) = **AB**DE
  - Do not merge(**A**BD,**A**CD) because they share only prefix of length 1 instead of length 2

→ A podagem já é feita após a criação dos [illegible]

→ Após a criação dos candidatos, para usar a região, usa a estrutura hash e medida da [illegible] cada bucket para um subconjunto de transações. Para fazer faz-se o direcionamento de

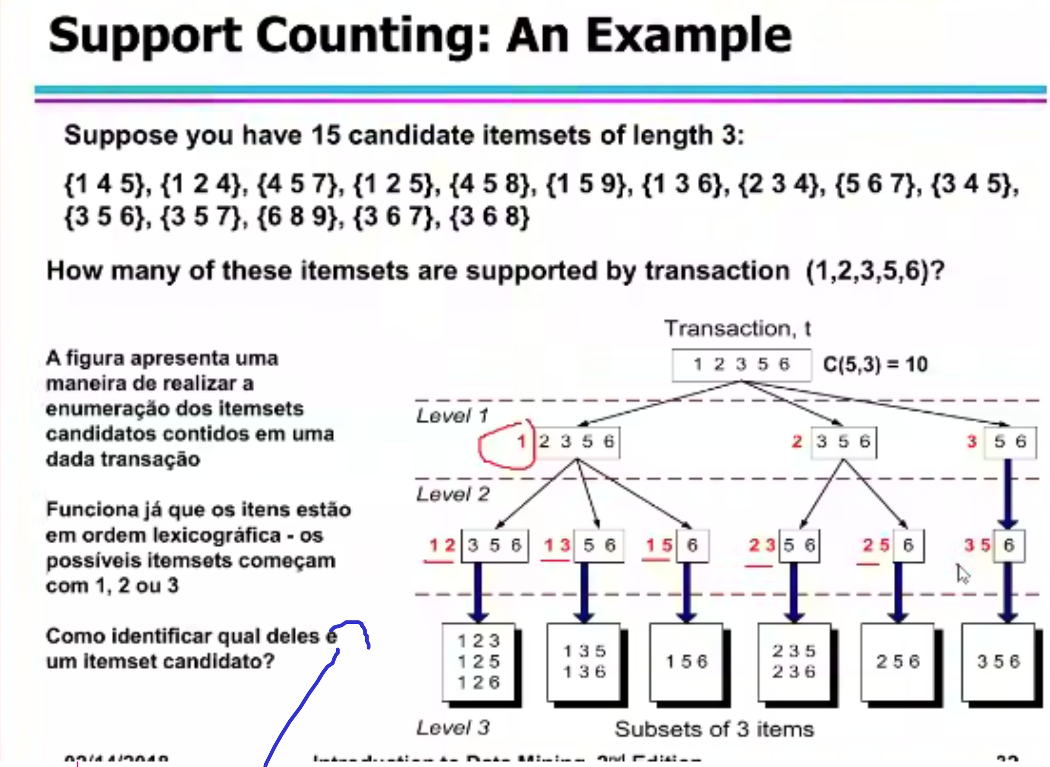

Support Counting: An Example

Suppose you have 15 candidate itemsets of length 3:

{1 4 5}, {1 2 4}, {4 5 7}, {1 2 5}, {4 5 8}, {1 5 9}, {1 3 6}, {2 3 4}, {5 6 7}, {3 4 5}, {3 5 6}, {3 5 7}, {6 8 9}, {3 6 7}, {3 6 8}

How many of these itemsets are supported by transaction (1,2,3,5,6)?

A figura apresenta uma maneira de realizar a enumeração dos itemsets candidatos contidos em uma dada transação

Funciona já que os itens estão em ordem lexicográfica - os possíveis itemsets começam com 1, 2 ou 3

Como identificar qual deles é um itemset candidato?

Transaction, t
1 2 3 5 6
C(5,3) = 10
Level 1
1 2 3 5 6
2 3 5 6
3 5 6
Level 2
1 2 3 5 6
1 3 5 6
1 5 6
2 3 5 6
2 5 6
3 5 6
1 2 3
1 2 5
1 2 6
1 3 5
1 3 6
1 5 6
2 3 5
2 3 6
2 5 6
3 5 6
Level 3
Subsets of 3 items

dado estão em ordem alfabética, isso é um radix trie podemos utilizar uma função hash para cada dígito

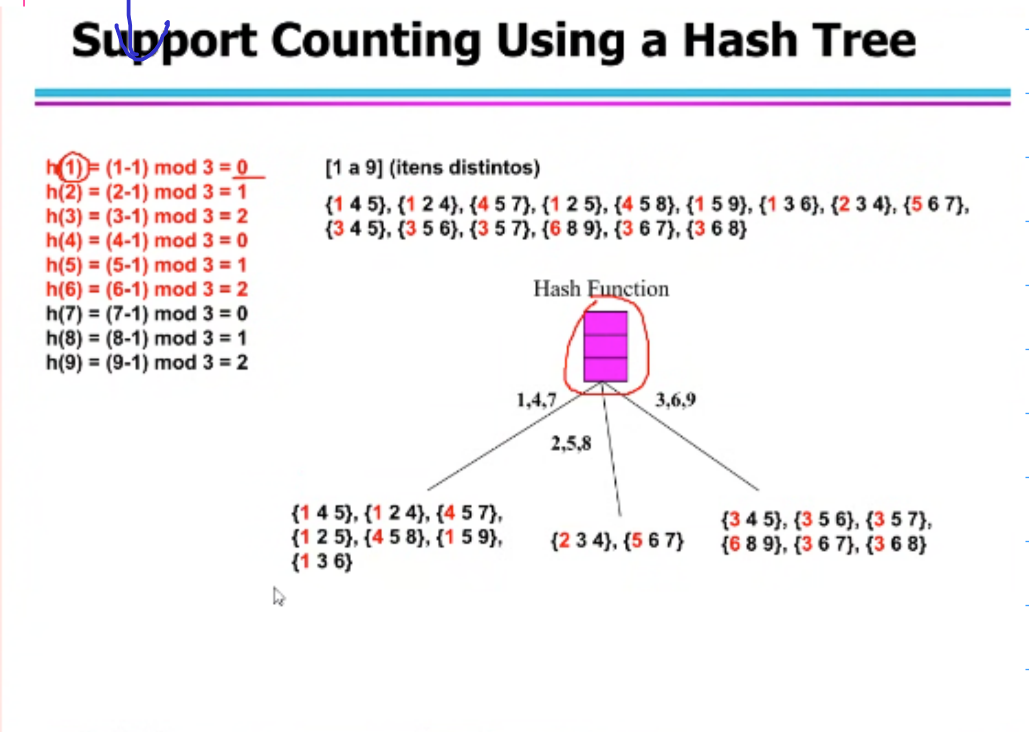

Support Counting Using a Hash Tree

h(1) = (1-1) mod 3 = 0
h(2) = (2-1) mod 3 = 1
h(3) = (3-1) mod 3 = 2
h(4) = (4-1) mod 3 = 0
h(5) = (5-1) mod 3 = 1
h(6) = (6-1) mod 3 = 2
h(7) = (7-1) mod 3 = 0
h(8) = (8-1) mod 3 = 1
h(9) = (9-1) mod 3 = 2

[1 a 9] (itens distintos)

{1 4 5}, {1 2 4}, {4 5 7}, {1 2 5}, {4 5 8}, {1 5 9}, {1 3 6}, {2 3 4}, {5 6 7}, {3 4 5}, {3 5 6}, {3 5 7}, {6 8 9}, {3 6 7}, {3 6 8}

um algoritmo é usado para encontrar itemsets

Para criar regras, usam-se os candidatos e a primeira regra, pegando aquelas de maior confiança (confiança não tem a propriedade anti-monotônica, mas apenas aquelas que saem do mesmo itemset

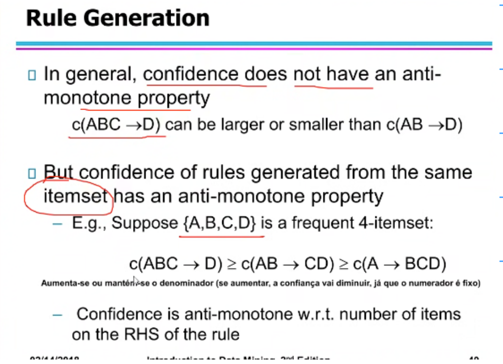

Rule Generation

- In general, confidence does not have an anti-monotone property
  - c(ABC →D) can be larger or smaller than c(AB →D)
- But confidence of rules generated from the same itemset has an anti-monotone property
  - E.g., Suppose {A,B,C,D} is a frequent 4-itemset:

$$c(ABC \rightarrow D) \geq c(AB \rightarrow CD) \geq c(A \rightarrow BCD)$$

Aumenta-se ou mantém-se o denominador (se aumentar, a confiança vai diminuir, já que o numerador é fixo)

  - Confidence is anti-monotone w.r.t. number of items on the RHS of the rule

→ para interpretabilidade geralmente escolhe regras que tem o apenas 1 item

→ é necessário pós-processamento para filtrar itens que não são úteis e inúteis em tudo

→ alguns itemsets podem ser redundantes por causa do suporte dos supersets. Para facilitar precisa-se de uma representação compacta

→ itemsets frequentes maximais → itemsets que são frequentes e não possuem filho que são frequentes

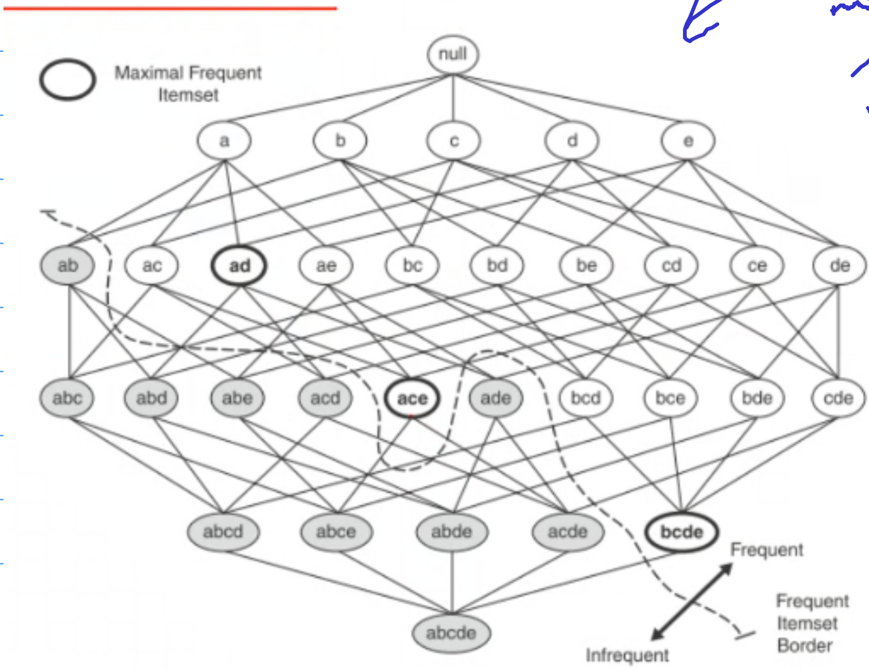
Maximal Frequent Itemset
null
a
b
c
d
e
ab
ac
ad
ae
bc
bd
be
cd
ce
de
abc
abd
abe
acd
ace
ade
bcd
bce
bde
cde
abcd
abce
abde
acde
bcde
abcde
Frequent
Infrequent
Frequent Itemset Border

os únicos de maximos dados, e para mostrar ad, ace, bcde e obter dados longos redigimos com os itens de ad, ace, bcde

como ac, bc, etc

→ Uma questão difícil é que não é possível inferir a frequência de ativação para [illegible] é [illegible] mas o itemset fechado

→ Itemset fechado pode ser frequente ou não

→ Itemset fechado é aquele que os seus superconjuntos (filhos) não [illegible] (um suporte) do que ele

→ Quando não fechado e frequente então não máximo

→ Para saber o suporte de um conjunto (pai·[illegible]) de um itemset fechado, então o dele é o máximo de seus filhos itemsets fechados

→ Apriori degrada a performance com o tamanho do dataset

→ Algoritmo de travessia bottom-up (aprofunda no grafo) não bottom para encontrar rapidamente os itemsets máximos

→ FP-growth → usa uma árvore de itens frequentes (FP-tree)

↳ percorre o dataset 2 vezes e não gera candidatos

↳ bastante comprimida

1: Conta os itens distintos e ordena em ordem decrescente

2: ordena as transações com base na sequência de ordem decrescente de frequência

3: Gera a FP-tree. Para cada transação ele monta a árvore com base na frequência de forma que o prefixo não é repetido (itens compartilhados)

obs: se cada transação for diferente, então terá um caminho na árvore para cada. Por isso, o algoritmo presume que itens sejam frequentes

4: guarda em memória uma lista de itens frequentes e uma lista encadeada para os nós da árvore que eles têm aquele item

→ Para gerar o itemset frequente o algoritmo vai do item menos frequente para o mais frequente (de baixo para cima da FP tree), pega o caminho gerado por aquele sufixo, pega o prefixo encontrado e que as combinações entre prefixo e o item atual

→ métricas
→ medida de interesse → o quão interessante são as regras (support e confiança pra começar)

métricas não derivadas de tabelas

pode ser frequência relativa também

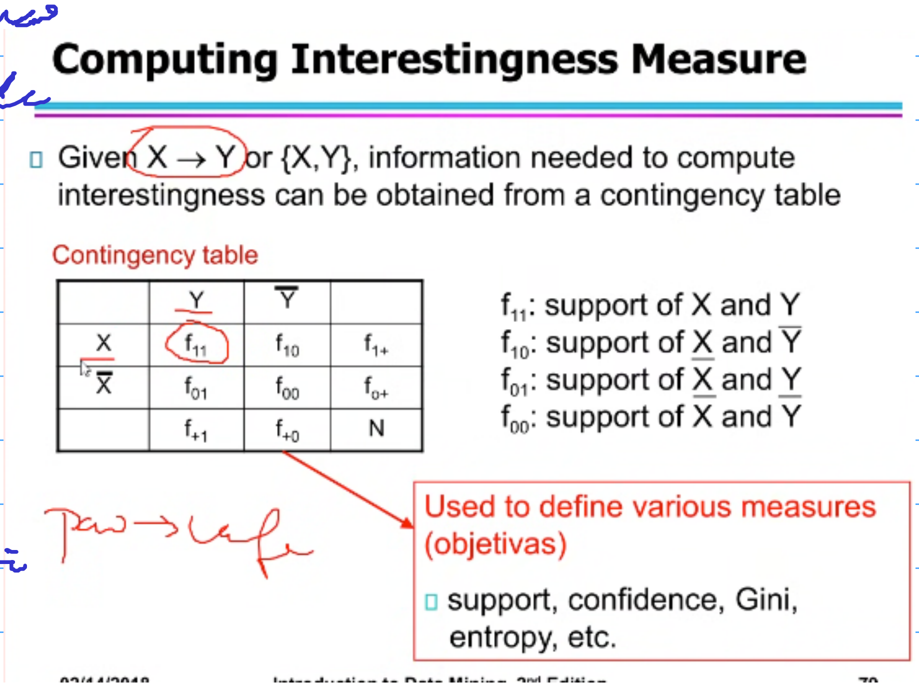

Computing Interestingness Measure

- Given X → Y or {X,Y}, information needed to compute interestingness can be obtained from a contingency table

Contingency table

	Y	$\overline{Y}$	
X	f_{11}	f_{10}	f_{1+}
$\overline{X}$	f_{01}	f_{00}	f_{o+}
	f_{+1}	f_{+0}	N

f_{11}: support of X and Y
f_{10}: support of X and $\overline{Y}$
f_{01}: support of $\overline{X}$ and Y
f_{00}: support of $\overline{X}$ and $\overline{Y}$

Pão → Café

Used to define various measures (objetivas)

- support, confidence, Gini, entropy, etc.

subjetivas → levam em consideração o conhecimento do domínio acertam os claros

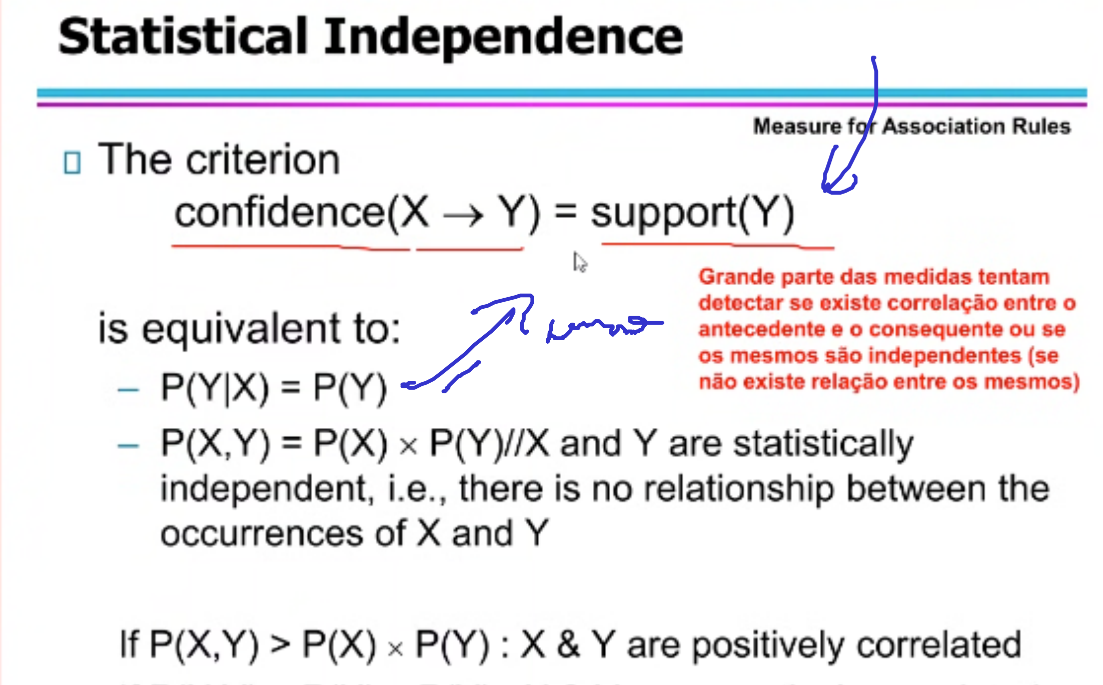

Statistical Independence

Measure for Association Rules

- The criterion

  confidence(X → Y) = support(Y)

  is equivalent to:

  – P(Y|X) = P(Y)

  – P(X,Y) = P(X) × P(Y)//X and Y are statistically independent, i.e., there is no relationship between the occurrences of X and Y

If P(X,Y) > P(X) × P(Y) : X & Y are positively correlated

If P(X,Y) < P(X) × P(Y) : X & Y are negatively correlated

Grande parte das medidas tentam detectar se existe correlação entre o antecedente e o consequente ou se os mesmos são independentes (se não existe relação entre os mesmos)

mesmo

medidas intrínsecas → tanto faz
X → Y ou
Y → X
↳ não mede a força
da implicação

Lift é geralmente usado para ver o tipo de correlação e se não tem (próximo de 1), negativo (< 1) e positivo (> 1)

$$\text{lift} = \frac{\text{confiança}}{P(Y)} \leftarrow P(Y|X)\ \epsilon_{X \to Y}$$

→ Escolher a melhor medida é complicado

→ we should move on a left