20
10
26

→ Aprendizado Semissupervisionado
↳ parte pequena é rotulada e o resto não
↳ dados não rotulados ajudam a aumentar o desempenho
↳ dados não rotulados ajudam pois é possível extrair a estrutura dos dados (manifold)
↳ como os valores se relacionam entre si

→ Indutivo → aprende $f: X \to Y$ em todo o espaço X e retorna previsões para pontos de teste

→ Transdutivo → estima um conjunto finito de teste $f: X_u \to Y$
↳ não generaliza, é usado apenas durante o teste
↳ até cria um modelo, mas o que ele diz é com base na geometria dos dados, classifica os não rotulados na só vez

→ Meta algoritmos → usa algoritmos de classificação como um meio para incorporar a fronteira de aprendizado
→ self-training, co-training

→ Variação de algoritmos clássicos → pega os clássicos e vira semi-supervisionado
↳ Bayes, TSVM, etc

→ não baseado em suposição
↳ 1- suavidade → pontos x_1, x_2 estão em uma região de alta densidade, então eles tem o mesmo rótulo
↳ 2- Manifold → dados de alta dimensão pode ser projetado a uma estrutura de menor dimensão
↳ curse of dimensionality
↳ pontos próximos, então o rótulo não correspondente | (?)
↳ grafos
↳ menor distância (geodésica) de caminho em um grafo

→ algum também pega via cluster e densidade

→ Self training → primeiro treina o algoritmo de classificação
↳ treina só com dados rotulados
iterativo ↳ rotula os não rotulados com pseudo label, considerando corretos aqueles de maior confiança (k)

↳ estrutura e classificada

→ predições muito iniciais propagam durante o processo

→ Co Training → assumir que as features podem ser particionadas em 2 de forma que sejam independentes e consigam ajudar a aprender o rótulo
↳ mais robusto ao ruído
↳ constrói dois classificadores
↳ não podem interagir diretamente
↳ Cada modelo é treinado em um set
↳ Depois cada modelo treinado faz a predição e pega o K mais confiante
↳ Um passa o seu K para o outro
↳ a cada iteração a quantidade de unlabeled de cada lado diminui

→ Baseado em grafo
↳ requer uma medida de distância
↳ propagação de labels
↳ Vértices similares possuem mesma classe
↳ para construção do grafo
↳ E-vizinhança → conecta se a distância entre dois pontos é menor que E
↳ pode gerar grafos desconexos

→ Viés KNN → dois pontos não conectados se estão entre os K vizinhos mais próximos
↳ pode gerar assimetria
→ KNN mútuo e simétrico são usados para tirar essa assimetria
→ propagação é feita com base na matriz de transição (prob)
→ é transdutivo

→ Aprendizado Ativo → dados rotulados, não rotulados e um oráculo
↳ melhorar a acurácia com um custo específico de aquisição de label
↳ interage com um processo de aquisição de label
↳ Hipótese → se o algoritmo pode escolher a instância, ele pode aprender melhor com menos instâncias
↳ Em instâncias que ele tem dúvida, ele pergunta para um oráculo (pode ser um humano ou máquina!)
↳ para isso é necessário um critério que gere qualid

→ diferente do semi supervisionado ele pega as instâncias de menor certeza. Entretanto não a que estão na fronteira

→ Cenários →

↳ Pool based → seleciona de um Pool de instâncias não rotuladas

segue que os dados unlabeled seja estáticos

Stream based → lê instância por instância, o modelo pergunta se é [illegible] ou não, vale a pena é para perguntar

→ Estratégias de Query

→ Heterogeneity → assume que features de decisão são dados heterogêneos

→ Performance based → quantifica o impacto de adicionar uma instância

→ Representatividade → verifica se uma instância é representativa na distribuição

→ Uncertainty sampling → Heterogeneity
↳ seleciona instância de menor certeza
↳

→ Classificação multirrótulo → instância pertence
↳ a duas ou mais classes
↳ filme, música, etc
↳ existe correlação entre classes
↳ modelo deve ser capaz de capturar essas correlações

→ Abordagens
→ independente de algoritmo
→ algoritmos clássicos, transforma-se múltiplos rótulos em monorrótulo

→ Binary Relevance (BR)
→ K classificadores (K = nº classes)
→ OVA
→ Neste caso é necessário combinar respostas, as respostas positivas são as classificações de rótulo para a nova instância.
→ capaz de prever conjuntos de rótulos que não estão na base
→ O(N) = O(K)
→ ignora correlação entre rótulos de classe

→ Label powerset (LP)
→ para todas as combinações de labels presentes no treino uma nova classe
→ aumento considerável o número de classes

- → Visão multiclasse, pode ser decomposto em um classificador multilabel
- → correlação entre rótulos é levada em consideração
- → não consegue prever conjuntos que não estavam nos dados (alguns rótulos não aparecem)
- → pode crescer exponencialmente em nº de classes

→ Ranking by Pairwise Comparison (RPC)
- → compara par a par
- → OvO
- → instâncias que possuem a combinação
- → ignorando se ambas as classes ou não foi considerada
- → nova instância passa por todo o classificador
- → Precisa-se de um limiar de votos para saber qual classe não
- → Consegue prever rótulos que não estavam na base
- → adiciona a correlação
- → O(N²)
- → depende do limiar