27/12/26

→ Cardinalidade dos rótulos → na média quantos rótulos tem cada instância

→ Densidade → frequência relativa da cardinalidade

↳ a cardinalidade de dataset pode ser igual, mas a densidade pode mudar se a quantidade de rótulos

→ Medidas de avaliação

↳ classificação podem estar parcialmente certa/errada

↳ acurácia → é modificada para comparar o conjunto real com o predito. Neste caso ele leva em consideração o conjunto de rótulos e uma interseção

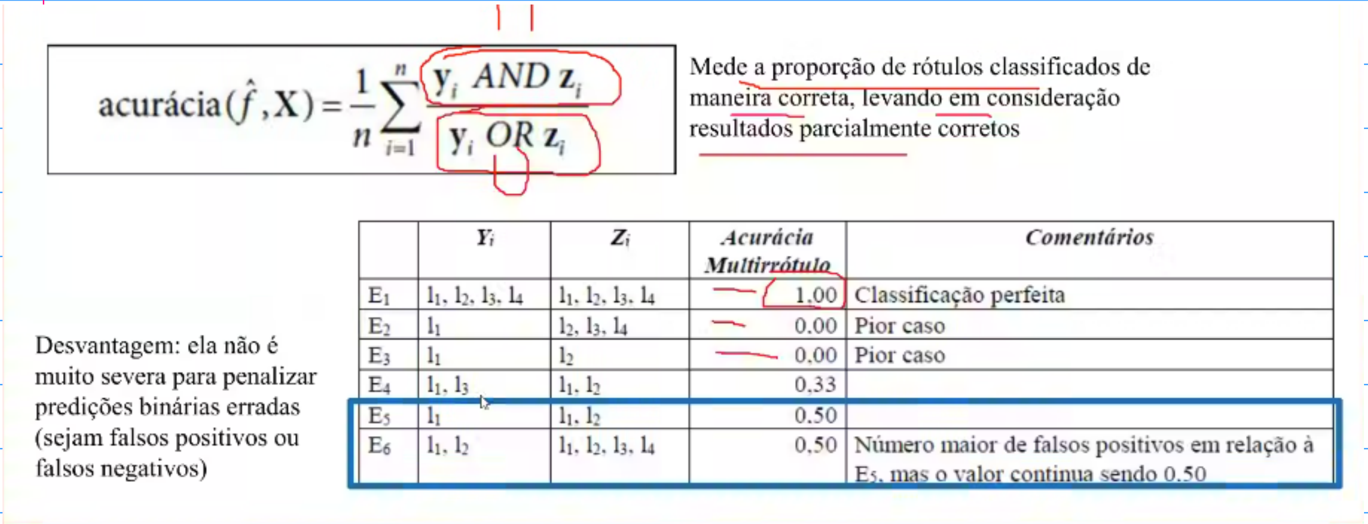

$$\text{acurácia}(\hat{f}, X) = \frac{1}{n}\sum_{i=1}^{n} \frac{y_i \ AND \ z_i}{y_i \ OR \ z_i}$$

Mede a proporção de rótulos classificados de maneira correta, levando em consideração resultados parcialmente corretos

Desvantagem: ela não é muito severa para penalizar predições binárias erradas (sejam falsos positivos ou falsos negativos)

	Y_i	Z_i	*Acurácia Multirrótulo*	*Comentários*
E_1	l_1, l_2, l_3, l_4	l_1, l_2, l_3, l_4	1.00	Classificação perfeita
E_2	l_1	l_2, l_3, l_4	0.00	Pior caso
E_3	l_1	l_2	0.00	Pior caso
E_4	l_1, l_3	l_1, l_2	0.33	
E_5	l_1	l_1, l_2	0.50	
E_6	l_1, l_2	l_1, l_2, l_3, l_4	0.50	Número maior de falsos positivos em relação à E_5, mas o valor continua sendo 0.50

↳ Hamming Loss é diferença simétrica entre o acerto '(XOR)

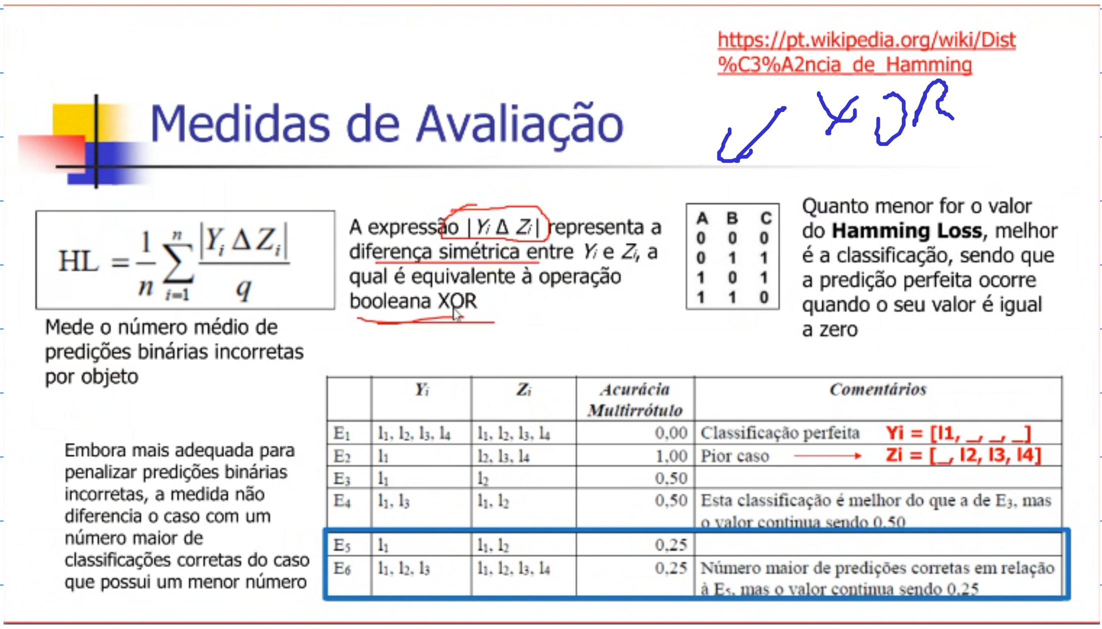

https://pt.wikipedia.org/wiki/Dist%C3%A2ncia_de_Hamming

✓ XOR

Medidas de Avaliação

$$HL = \frac{1}{n}\sum_{i=1}^{n}\frac{|Y_i \Delta Z_i|}{q}$$

Mede o número médio de predições binárias incorretas por objeto

A expressão $|Y_i \Delta Z_i|$ representa a diferença simétrica entre Y_i e Z_i, a qual é equivalente à operação booleana XOR

A	B	C
0	0	0
0	1	1
1	0	1
1	1	0

Quanto menor for o valor do **Hamming Loss**, melhor é a classificação, sendo que a predição perfeita ocorre quando o seu valor é igual a zero

Embora mais adequada para penalizar predições binárias incorretas, a medida não diferencia o caso com um número maior de classificações corretas do caso que possui um menor número

	Y_i	*Z_i*	*Acurácia Multirrótulo*	*Comentários*
E_1	l_1, l_2, l_3, l_4	l_1, l_2, l_3, l_4	0,00	Classificação perfeita **Yi = [l1, _, _, _]**
E_2	l_1	l_2, l_3, l_4	1,00	Pior caso → **Zi = [_, l2, l3, l4]**
E_3	l_1	l_2	0,50	
E_4	l_1, l_3	l_1, l_2	0,50	Esta classificação é melhor do que a de E_3, mas o valor continua sendo 0,50
E_5	l_1	l_1, l_2	0,25	
E_6	l_1, l_2, l_3	l_1, l_2, l_3, l_4	0,25	Número maior de predições corretas em relação à E_5, mas o valor continua sendo 0,25

↳ Mesma ideia pode ser usada para regressão. Podem Margem maior de resultado para funcionar

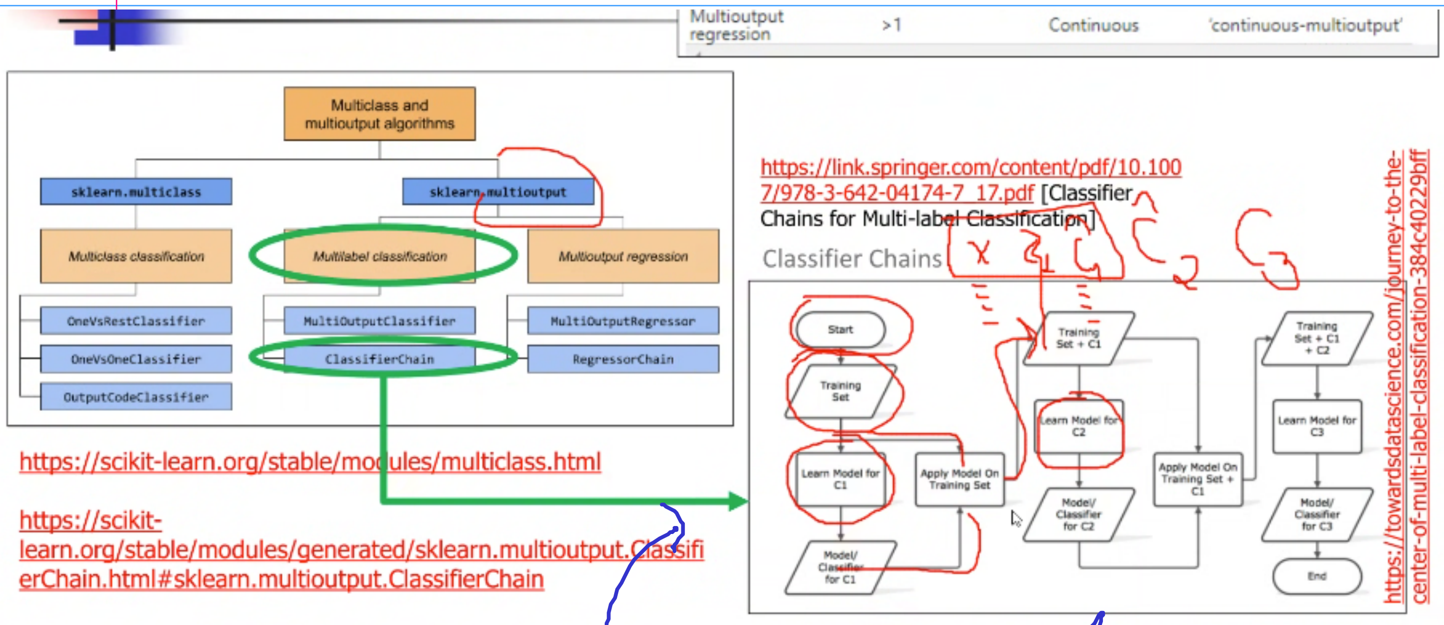

Multioutput regression	>1	Continuous	'continuous-multioutput'

Multiclass and multioutput algorithms

- sklearn.multiclass
  - Multiclass classification
    - OneVsRestClassifier
    - OneVsOneClassifier
    - OutputCodeClassifier
- sklearn.multioutput
  - Multilabel classification
    - MultiOutputClassifier
    - ClassifierChain
  - Multioutput regression
    - MultiOutputRegressor
    - RegressorChain

https://scikit-learn.org/stable/modules/multiclass.html

https://scikit-learn.org/stable/modules/generated/sklearn.multioutput.ClassifierChain.html#sklearn.multioutput.ClassifierChain

https://link.springer.com/content/pdf/10.1007/978-3-642-04174-7_17.pdf [Classifier Chains for Multi-label Classification]

Classifier Chains

https://towardsdatascience.com/journey-to-the-center-of-multi-label-classification-384c40229bff

X
Z_1
C_1
C_2
C_3
Start
Training Set
Learn Model for C1
Model/Classifier for C1
Apply Model On Training Set
Training Set + C1
Learn Model for C2
Model/Classifier for C2
Apply Model On Training Set + C1
Training Set + C1 + C2
Learn Model for C3
Model/Classifier for C3
End

método em cadeia incorpora as predições das anteriores para uma nova label

↳ ordem do escalonamento impacta o modelo

↳ Se o modelo tem múltiplas saídas e elas não independentes, então há a possibilidade de fazer a classificação, no outro lado se tiver correlação deve pensar de outra forma

→ Detecção de anomalias / outliers
  ↳ Busca de valores que desviam do valor normal (esperado) do domínio
  ↳ outliers podem ser importantes em certos casos
  ↳ muitos métodos não são baseados em distribuição estatística para ser difícil

→ Características dos dados
  → Univariado e multivariado
    ↳ univariado → valor desvia em um atributo
    ↳ multivariado → o objeto como um todo desvia
  → Pode originar a matriz de proximidade

→ Supervisionado ou, não supervisionado
ou semi supervisionado
↳ no geral são não supervisionado

→ Quantidade de dados [illegible]

→ Como os atributos estão distribuídos
↳ distribuição ou não

→ baseado / livre de modelo
→ baseado em modelo → [illegible]
não pontos que distorcem o modelo
→ livre de modelo → não se baseia
no modelo mas sim nos dados
↳ mais intuitivo

→ Global / local
→ global olha todos e ajusta
→ local → vizinhos

→ Bias Vs var
→ diz se é ou não um outlier (Bias)
→ a ainda faz um seguro bom
no ranking vai def...

- → baseado em distância / proximidade
  - → instância longe das outras
  - → instâncias [illegible] então ponto
  - → model-free, local, baseado em score (maior score = outlier)
  - → score é a distância ao n K vizinhos mais próximos (até vizinho, não o K)
  - → é sensível ao valor K
    - ↳ clusters pequenos pode ser um outlier dado até isolado
  - → para utilizar isso, geralmente é usado a média

- → baseado em densidade
  - → pontos em regiões de baixa densidade
  - → DBSCAN
  - → sensível ao parametro d (em DBSCAN é o raio, no geral a distância)
  - → similar ao de proximidade (só de prox. tem que ser usado diferente K para ver a [illegible] tem no raio)

- → Score de densidade relativa
  - → dados que formam regiões com densidades diferentes
  - → comparar densidade do ponto com os vizinhos
  - → densidade vizinhos média pode ser a densidade média também

→ Local outlier factor
é um dos scoring
↳ knd, model free, non
↳ compara a densidade local do ponto com a densidade local dos vizinhos

k-distância → distância do ponto ao k° vizinho
K-vizinhos → pontos dentro do raio ~~entre os pontos~~ a K distância
distância de alcance (RD) →

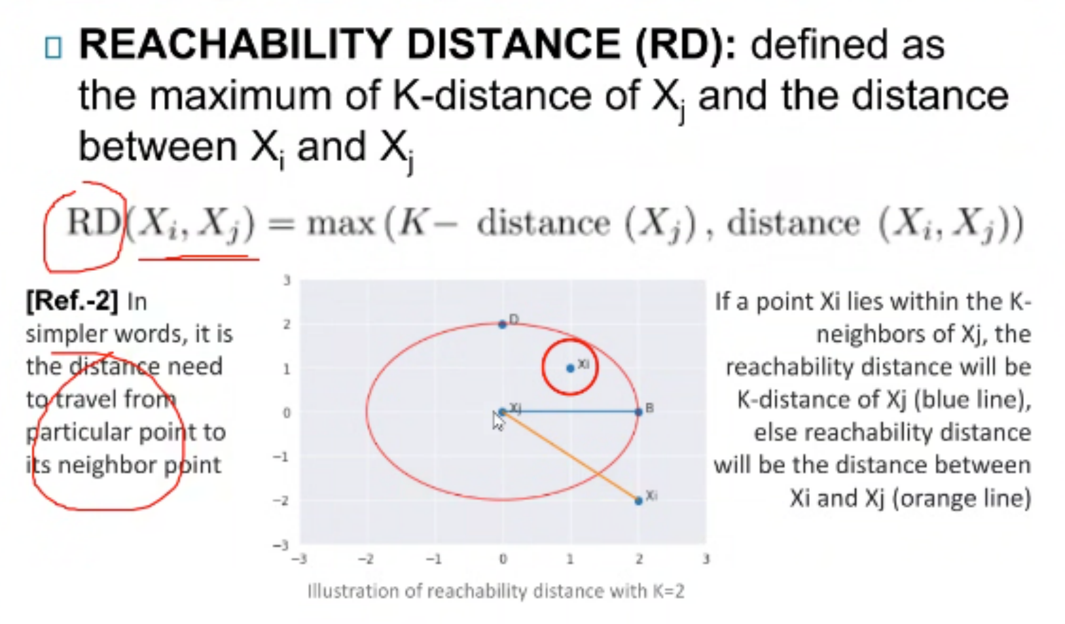

☐ **REACHABILITY DISTANCE (RD):** defined as the maximum of K-distance of X_j and the distance between X_i and X_j

$$\mathrm{RD}(X_i, X_j) = \max\left(K\text{– distance } (X_j), \text{distance } (X_i, X_j)\right)$$

[Ref.-2] In simpler words, it is the distance need to travel from particular point to its neighbor point

If a point Xi lies within the K-neighbors of Xj, the reachability distance will be K-distance of Xj (blue line), else reachability distance will be the distance between Xi and Xj (orange line)

Illustration of reachability distance with K=2

distância é máxima entre x_i e x_j ou o raio e a distância real (caso fora do raio)

Densidade local alcançável (LRD) → quanto maior, mais próximo o ponto está do seu cluster mais próximo

→ LOF → se os vizinhos estão em uma área de alta densidade e o ponto não, ele deve ser um outlier
→ Vantagens, mostra outliers que estão próximos de clusters (de qualquer forma)
→ Desvantagens → não é possível interpretar
→ [illegible]

→ baseado em distâncias são lentos

→ Baseado em clusters
→ outliers não se ajustam ao agrupamento ou em clusters pequenos
→ validados por exemplo (para instâncias)
→ classificar clusters
→ outliers em si podem distorcer os clusters, o que pode ser mascarado por outros outliers

→ Baseado em Reconstrução
→ assume que há padrões que podem ser capturados em menor dimensão
→ PCA, Autoencoders etc
→ depois é reconstruído a partir de maior dimensão.
→ instâncias com maior erro de reconstrução são outliers

- Uma única classe
  - Ex: 1-class SVM
  - dados desbalanceados
  - o que não está no padrão da classe positiva está na outra classe
    - ↳ não é classificação binária, semi-supervisionado
  - modelo é sensível ao parâmetro

- Baseado em Teoria da Informação
  - classe normal pode ser representada
  - quantifica a quantidade de informação necessária para codificar
  - o quanto a informação decai ao deletar instância (ganho)
  - pontos com tem seu ganho
  - ~~[illegible]~~ subconjunto é removido
  - problema de otimização

- Avaliação
  - na base rotulada é possível usar métricas como F1, recall, etc.
  - o padrão é usar a taxa de falso positivo x falso positivo
  - ponto é um outlier
  - Verdadeiro positivo é minoritário

→ e não [illegible] label globalmente mas em histogramas. A ideia é que poucos terem valor grande (para LOF por exemplo)

→ Isolation Forest
- → Similar ao Random Forest
- → não supervisionado
- → anomalias que são profundamente [illegible] [illegible] [illegible] [illegible] chamados de os outliers
- → dá um score entre 0 - 1

→ detecção de novidade → treino é limpo
✓ ↳ quando [illegible] se tem não contaminação é um outlier