

Classificador para Doença de Alzheimer

Alexandre Silva

alexandre.silva1@unesp.br

1 Introdução

A Doença de Alzheimer é um transtorno neurodegenerativo progressivo que se manifesta pela deterioração cognitiva e da memória [1]. Esta doença, é a principal forma de demência, representando cerca de 60-70% dos casos no mundo [2]. A OMS estima que até 2030 o número de casos deve chegar à casa dos 75 milhões, sendo a maioria dos casos pessoas vivendo em países com baixa e média renda [2].

Assim como a cartilha sobre demência publicada pela OMS em 2017 promove [2], é fundamental a coleta de dados e a implementação de sistemas que possam monitorar a evolução da doença na população, assim como a aparição de seus indicadores, promovendo melhores tratamentos e serviços de saúde.

2 Proposta

Motivados por esta cartilha [2] e por questões familiares. Neste trabalho propõem-se o desenvolvimento de uma pipeline para a criação de um modelo de classificação para a doença de Alzheimer.

O dataset utilizado para isso será proveniente de uma competição do Kaggle, da qual pode ser encontrada em [3].

Neste trabalho, visa-se responder a questão: **Modelos treinados baseando-se, somente, em dados de estilo de vida e testes clínicos conseguem assertividade equiparada à modelos dotados de maiores informações sobre o paciente?**

Esta questão é baseada nas pesquisa disponíveis em [4] e [5], das quais demonstram a forte ligação entre fatores como tabagismo, pouca atividade física e pressão alta, à demência. Neste caso, queremos validar se se baseando apenas nestes fatores, seria possível gerar modelos relativamente mais simples e com assertividade equiparável à modelos com mais informações sobre histórico do paciente.

3 Metodologia

Para isso, pretendo seguir a metodologia baseada em CRISP-DM. Essa escolha foi feita visto a necessidade de entendermos melhor o domínio do problema.

Neste caso, é preciso entender melhor os indicadores e outros fatores mais específicos da área médica. Sendo assim, essa metodologia se enquadraria melhor no que é necessário para este projeto.

Com relação aos algoritmos e relacionados, como revisado em [6], existem duas modalidades principais de métodos, sendo o primeiro baseado em imagens e outra baseada em dados clínicos e sobre a vida do paciente. No caso da segunda modalidade, modelos baseados em *Ensembles*, *Árvores de Decisão* e *Clusterização* foram mostrados como os mais difundidos para este tipo de dado.

Em [7], os autores aplicaram *Random Forest*, *KNN*, *Naïve Bayes* e *SVM* como classificadores para datasets providos pela *NACC* e *ADNI*. O objetivo deste projeto era buscar modelos que pudessem classificar indivíduos em múltiplas classes da doença de Alzheimer, usando modelos que são mais interpretáveis quando comparados com redes neurais. Como resultado, modelos baseados em *Random Forest* e *SVM* apresentaram os maiores níveis de *acurácia*, *precision* e *recall*.

Por fim, em [8], foi proposto um modelo classificador multimodal baseado em *Random Forest* em conjunto com modelos treinados para dar explicações sobre os resultados, auxiliando no diagnóstico médico.

Com base nesses estudos, pretende-se explorar métodos baseados em *ensemble*, sendo eles *Random Forest*, *AdaBoost* e *XGBoost*, devido a nossa curiosidade sobre o tópico. Além destes, também propomos o treinamento de modelos mais simples para comparação, como *Árvores de Decisão* e *Regressão Logística*.

Para avaliar os modelos, adotaremos os métodos aplicados nos estudos que utilizamos como base, sendo eles: *acurácia*, *precision* e *recall*. Além destes, propomos o uso de *F1 Score* e *ROC-AUC*. Dado que nossa classe alvo, "**Possui Alzheimer**", é binária, não é necessário nos preocuparmos com os métodos de média utilizados pelas métricas, sendo que para nós o mais importante são as instâncias de casos positivos para a doença.

Rotinas de pré-processamento podem ser baseados nas pipelines propostas por alguns dos artigos citados [7, 8, 6].

Uma vez que os dados do dataset são previamente repartidos em treino e teste. Utilizaremos Validação cruzada na porção designada para treino, de forma que amostras sejam divididas entre treino e validação, sendo a porção de validação utilizada para tunagem de *híper-parâmetros* dos modelos.

Outro fator a ser abordado neste trabalho, é a interpretação dos modelos gerados. Para isso, serão utilizados métodos como *Gini* (para árvores) e *SHAP*. Estes, nos ajudarão a entender como cada atributo usado no treinamento contribui para o modelo final.

4 Cronograma

O cronograma proposto para este trabalho segue-se a baixo:

Atividade	Datas
Entender o domínio	8 Setembro - 18 Setembro
Explorar os dados	21 Setembro - 29 Setembro
Busca de Hiperparâmetros e Treinamento	30 Setembro - 02 Outubro
Verificação dos resultados (Visualizações)	5 Outubro - 9 Outubro
Deploy do melhor modelo criado (Streamlit)	12 Outubro - 13 Outubro
Criação do artigo	8 Setembro - 13 Outubro
Criação dos slides	13 Outubro - 20 Outubro

Como o *CRISP-DM* é uma metodologia iterativa e interativa, podemos regressar à etapas anteriores, caso necessário, para criar conhecimento mais sólido sobre o problema.

Referências

- [1] “Alzheimer — gov.br.” <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/a/alzheimer>. [Accessed 01-09-2026].
- [2] “Global action plan on the public health response to dementia 2017 - 2025 — who.int.” <https://www.who.int/publications/i/item/global-action-plan-on-the-public-health-response-to-dementia-2017---2025>. [Accessed 01-09-2026].
- [3] H. SFAR, “Alzheimer’s disease risk prediction - eu business.” <https://kaggle.com/competitions/alzheimers-disease-risk-prediction-eu-business>, 2025. Kaggle.
- [4] K. Dhana, D. A. Evans, K. B. Rajan, D. A. Bennett, and M. C. Morris, “Healthy lifestyle and the risk of Alzheimer dementia,” vol. 95, no. 4, pp. e374–e383.
- [5] T. T. Vu, L. Zhao, L. Liu, C. Schiman, D. M. Lloyd-Jones, M. L. Daviglus, K. Liu, D. B. Garside, J. Stamler, J. F. Fries, Y. T. Shih, and N. B. Allen, “Favorable Cardiovascular Health at Young and Middle Ages and Dementia in Older Age—The CHA Study,” vol. 8, no. 1, p. e009730.
- [6] M. R. Shaikh, A. Jeyabose, and R. V. Arjunan, “Deep learning for alzheimer’s disease: advances in classification, segmentation, subtyping, and explainability,” *BioMedical Engineering OnLine*, vol. 24, Dec. 2025.
- [7] A. S. Alatrany, W. Khan, A. Hussain, H. Kolivand, and D. Al-Jumeily, “An explainable machine learning approach for alzheimer’s disease classification,” *Scientific Reports*, vol. 14, Feb. 2024.
- [8] S. El-Sappagh, J. M. Alonso, S. M. R. Islam, A. M. Sultan, and K. S. Kwak, “A multilayer multimodal detection and prediction model based on explainable artificial intelligence for alzheimer’s disease,” *Scientific Reports*, vol. 11, Jan. 2021.